Föreläsning 5

Josef Wilzén

2023-02-20

Föreläsning 5: Innehåll

- Praktisk information om del II.
- Basgrafik
- Slumptal och simulering
- knitr och markdown
- Externa data och pxweb

R-programmering - del II

- Del 1: Grunderna i programmering
  - Variabler, tilldelning
  - Datastrukturer
  - Kontrollstrukturer
  - Funktioner
  - Debugging
- Del 2: Tillämpningar

R-programmering - del II

- Del 1: Grunderna i programmering
- Del 2: Tillämpningar:
  - Grafik
  - Statistik och analys
  - Externa data
  - Datum
  - Texthantering och regular expression
  - Linjär algebra
  - knitr, markdown, Literate programming

R-programmering - del II:

- Labbarna görs nu i par
- Parprogrammering:
  - **Turas om att skriva koden**
  - Den som inte kodar är engagerad i koden och problemet
  - Byter person var 20/30:e minut
  - Viktigt att kommentera koden: ROxygen, inline
  - **Båda** är delaktiga i programmeringen

Projekt del 1

Info här: *länk*

- Hitta data på webben $\rightarrow$ pxweb
  - Kommunala (tvärsnitt) data
  - Tidsseriedata
- Presentera med basgrafik, knitr och markdown
- Ska kunna vara reproducerbart
- Lämna in **PDF** och **.Rmd**
- Egen inlämning på Lisam
- Två veckors tid

Basgrafik

- Grafiken är en av styrkorna med R
- Olika paket: `ggplot2`, `lattice` m.m.
- Högnivå (funktioner, `plot`)
- Lågnivå (bygga upp en plot steg för steg)
- Används ofta för att snabbt visualisera data
- Använd grafik för att:
  - Sammanfatta tabeller/data visuellt
  - Jämföra olika dataset
  - Rita ut funktioner

Enkel grafik: plot()

- `plot()` - kan plotta många olika objekt:
  - `plot(x,y)`, ger en scatterplot, här är x och y vektorer som ger x- och y-koordinater
  - `plot(X)`, om X en data.frame så skapas en matrix-plot
  - Vanliga argument: "`type=`","`main=`", "`xlab=`,"`ylab=`","`xlim=`,"`ylim=`", "`col=`"

Exempel: plot()

```
data(iris)
plot(x = iris$Sepal.Length,
     y = iris$Petal.Length, main = "Iris")
```

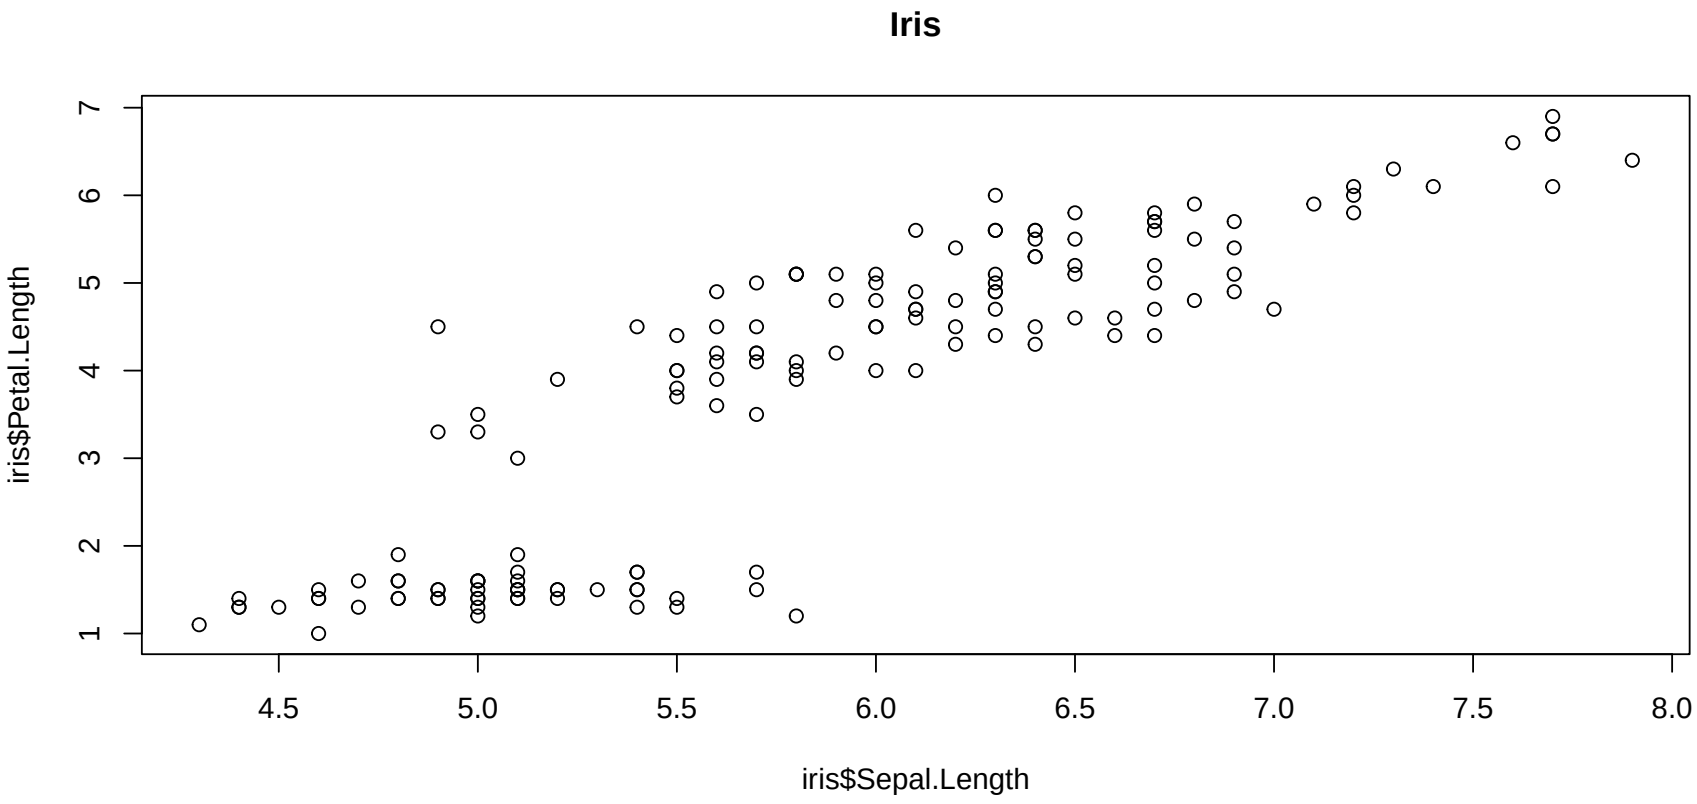

Olika diagramtyper

- `hist(x=,breaks=,freq=)` ger ett histogram,
  - "`x`"- numerisk vektor
  - "`breaks=`" - antal bins, default är att variationsområdet delas in i $log_2(n) + 1$ intervall
- `boxplot()` ger boxplot
- `barplot()` ger stapeldiagram
- `pie()` ger en piechart
- Använd hjälpen för att se exempel och fler argument

Exempel: hist()

```
hist(iris$Sepal.Length)
```

Exempel: boxplot()

```
boxplot(iris$Sepal.Length)
```

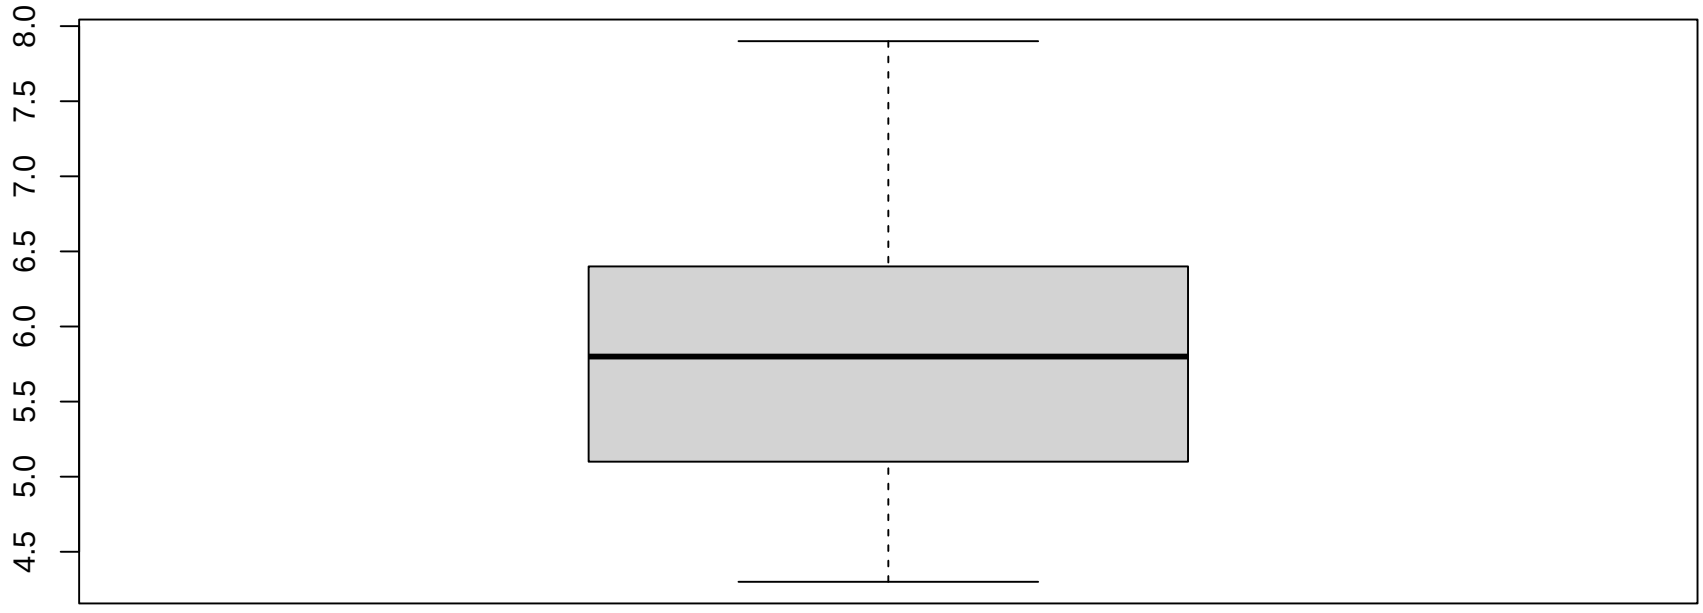

Exempel: pie()

```
tab <- table(iris$Species)
pie(tab)
```

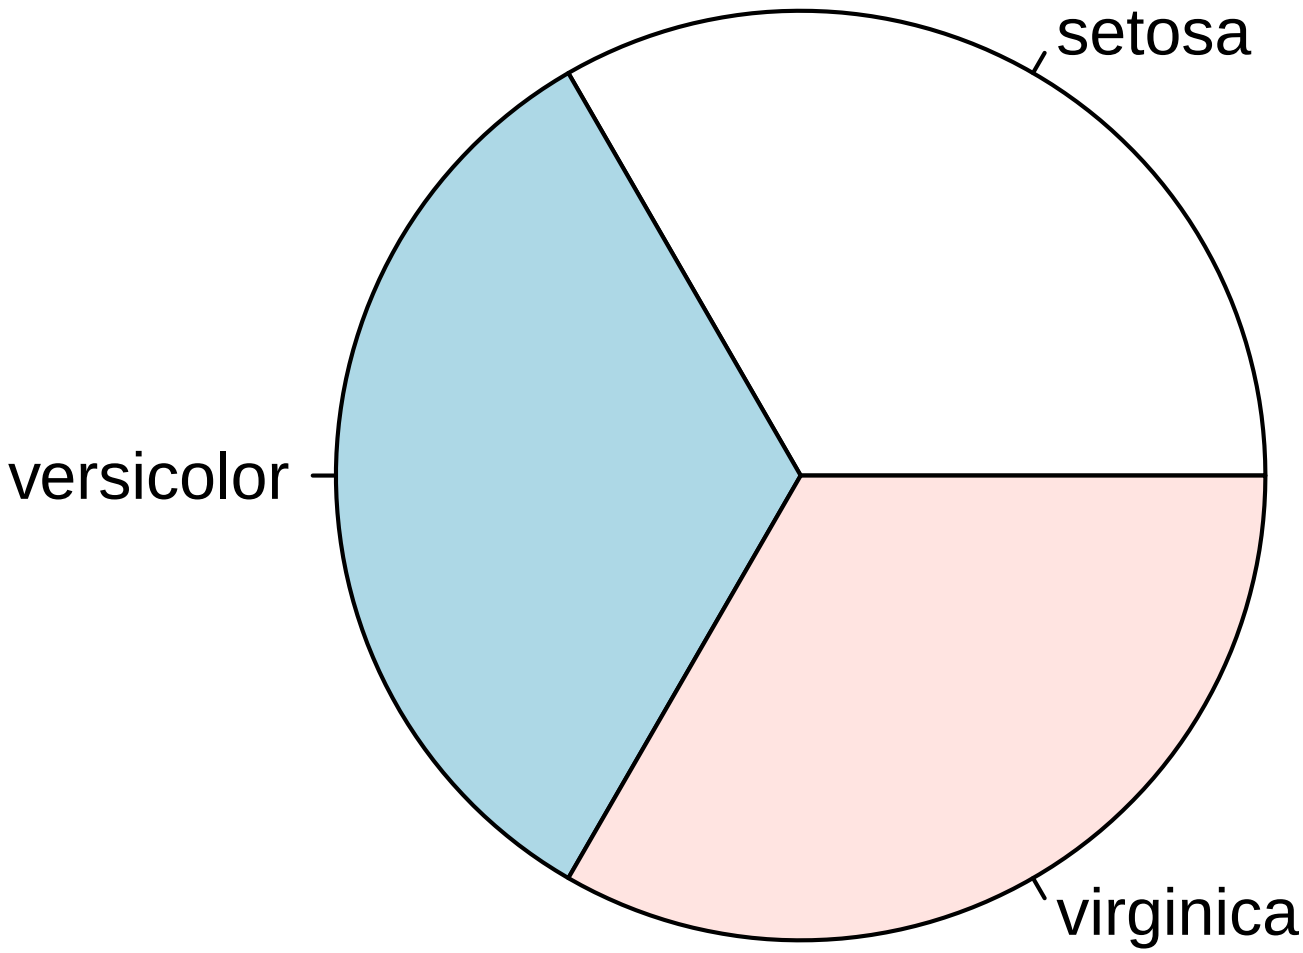

Exempel: barplot()

```
tab <- table(iris$Species)  # skapa frekvenstabell
barplot(tab,col=c("red","blue","pink"))
```

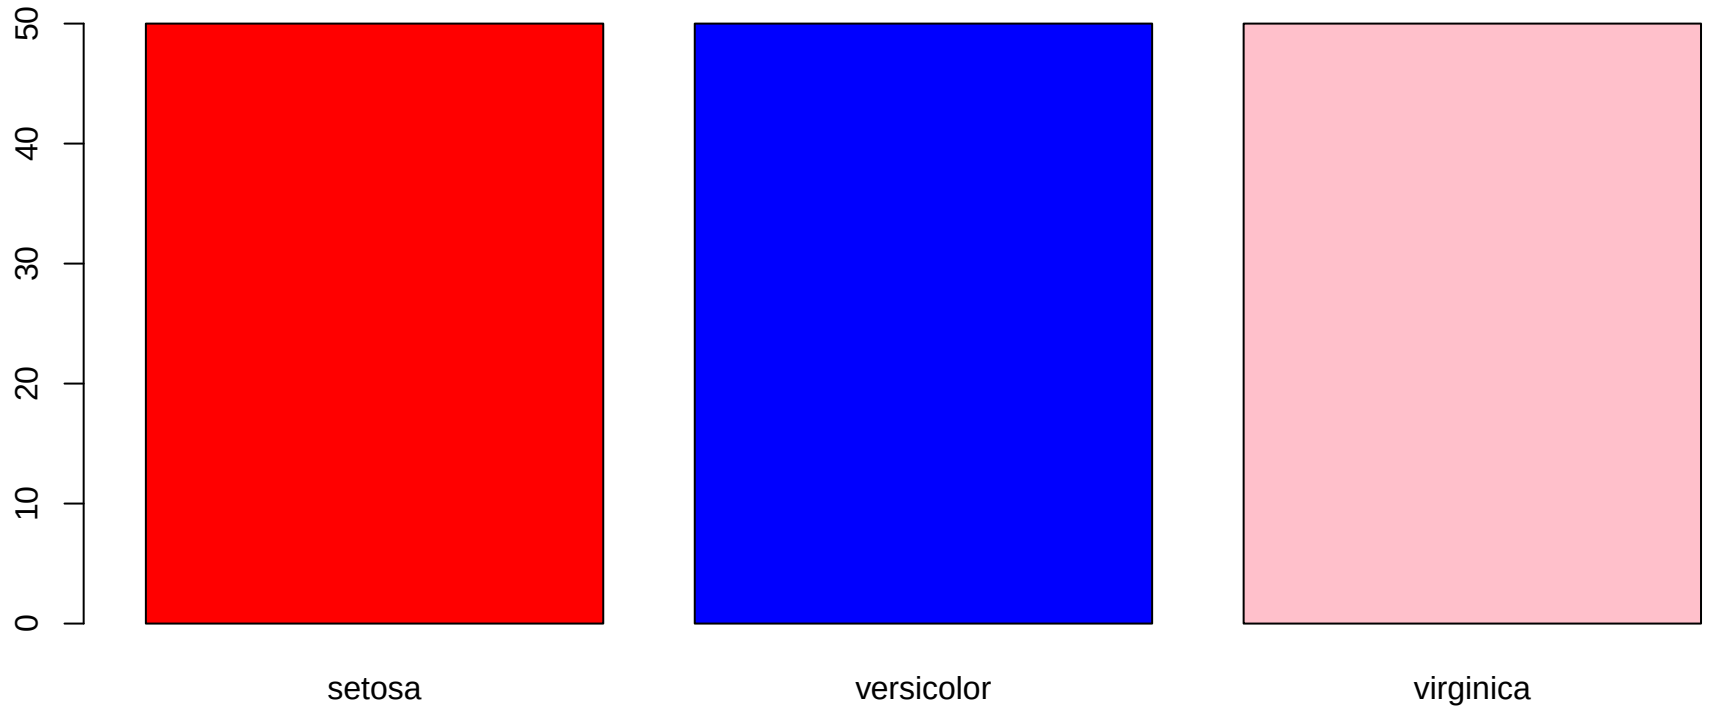

Lågnivågrafik

- Kan användas för att bygga upp en graf från grunden
- Lägger till "lager på lager":
  - `points(x, y, ...)` lägger till punkter
  - `lines(x, y)` lägger till linjer
  - `abline(a, b, h, v, ...)` lägger till räta linjer
  - `legend(x, y, legend, ...)` lägger till en förklaringsruta
  - `par()`: Fler grafiska alternativ

Lågnivågrafik

- Går att bygga upp många olika sorters plottar
- Dock är ggplot2 oftast **MYCKET** smidigare

Demo: Basgrafik

Slumptal och simulering

- I R finns en uppsättning funktioner för fördelningar

prefix	Beskrivning	Exempel
`r`	simulera från fördelningen	`rnorm()`
`d`	täthetsfunktionen (pdf)	`dnorm()`
`p`	kulmulativ fördelningsfunktion (cdf)	`pnorm()`
`q`	inversa kulmulativa fördelningsfunktionen	`qnorm()`

- `?Distributions`
- Se CRAN task view: Distributions *här*

Slumptal och simulering: Urval och slumpfrön

- Det finns ingen riktig slump i datorer
- Det finns slumptalsgeneratorer
- Kan styra "slumpen" med "slumpfrön" (`set.seed()`)
- För att dra ett (obundet) slumpmässigt urval använder vi `sample()`

Slumptal och simulering: Exempel

```
rnorm(n = 3, mean = 10, sd = 1)
```

```
## [1] 10.99805 11.59685 10.08714
```

```
set.seed(20180218)
rnorm(n = 3, mean = 10, sd = 1)
```

```
## [1] 10.19380 10.74998 11.32583
```

```
set.seed(20180218)
rnorm(n=3, mean=10, sd=1)
```

```
## [1] 10.19380 10.74998 11.32583
```

Slumptal och simulering: Exempel sample()

```
text <- c("Linköpings", "Universitet")
set.seed(20180218)
sample(x=text, size=3, replace=TRUE)
```

```
## [1] "Universitet" "Universitet" "Universitet"
```

```
set.seed(654)
sample(x=text, size=3, replace=TRUE)
```

```
## [1] "Universitet" "Linköpings"  "Universitet"
```

Demo: Slumptal

R-Markdown, Notebooks och knitr

- Kombinera text, kod och grafik i en fil.
- Förenkla för era laborationer i andra kurser
- Del av R-Studio
- Två delar:
  - Markdown (för text)
  - knitR (för R-kod)
- Kan skapa PDF, Word och/eller HTML (och presentationer)

Markdown

- Markupspråk (som HTML)
- Ersätter ofta HTML
- Enkelt
- Kan hantera matematik (med LaTeX)
- Integrerat med R-Studio
  - Kan behöva installera LaTeX för att skapa PDF

knitr

- Kör R-kod och ersätter med resultatet
- "Stickar ihop" text och kod
- "Dynamiska rapporter"
- För att skapa tabeller: `kable()`
- Kan hantera R och Python (och ev. SAS)

R-Studio Notebooks

- Är Rmd-filer
- Kan köras interaktivt direkt i R-Studio
- Inspiration från Jypyter Notebooks
- Skillnad mellan Markdown och Notebooks, läs *här*

Demo: Markdown och knitr

(Webbaserade) externa datakällor

Varför?

- Mer och mer data finns på webben
- Vill hantera detta programatiskt
- Kan vara lite klurigt i början
- Centralt för reproducerbarhet

Ladda ned och läsa in från webben

- Vill vi bara ladda ned: `downloader`
- Vill vi ladda in direkt i R: `repmis`

`repmis` hanterar: - .Rdata - .csv - .txt

Vanliga källor att använda

- Dropbox
- Google Docs
- Github
- etc. . .

Öppen data med pxweb api

- En "dörr" till pxweb apier
- `pxweb` är ett paket för att "gå in" genom dörren
- Fler och fler myndigheter använder pxweb api
- Kan användas för:
  - Navigera i datalager
  - Ladda ned förutbestämd data med kod (för produktion)

pxweb

```
install.packages("pxweb")
```

```
library(pxweb)
```

```
mitt_data<-pxweb_interactive()
```

Se även denna *vignette*

Demo: pxweb