

# R-programmering VT2022

## Föreläsning 7

---

Josef Wilén

2022-03-07

Linköpings Universitet

# Föreläsning 7

---

- Grafik med ggplot2
- Grundläggande statistik
- Linjär regression

## ggplot2

---

- Skapat av Hadley Wickham för över 10 år sedan
- Baseras på “Grammar of Graphics” av Leland Wilkinson
- Alternativ till basgrafiken
- Grunden är alltid en `data.frame`

- Abstraktion av grafiska idéer
  - Tänk språk med ordklasser/satsdeelar
- Ger ett teoretiskt ramverk för att bygga grafik.
- Bygga upp grafik lager för lager

- Bygger upp en graf av flera delar:
  - `data`: en `data.frame` med **all** data
  - `aes`: aesthetic mappings
  - `geom`: geometriska objekt
  - `facets`: subplottar
  - `scales`: skalar
  - `coordinate system`: koordinatsystem

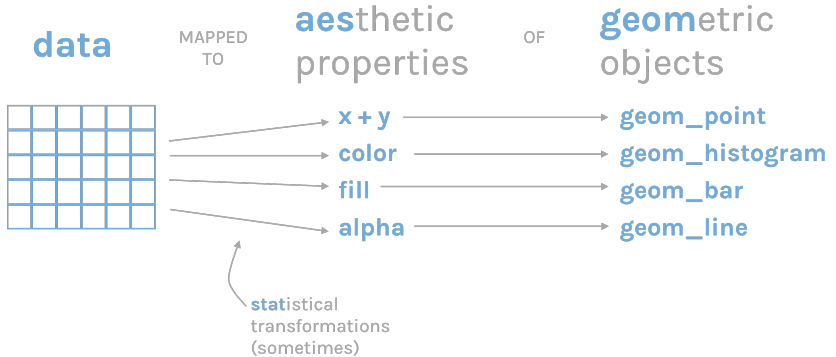


Bild från "R for the rest of us"



- `ggplot2` bygger upp en plot med olika lager
  - När plotten är klar så visas den
  - Kan också visa med `print()`
- Utgår från `ggplot()`
  - Returnerar ett objekt
- Adderar lager med `+`
  - t.ex. `+ geom_point()`
- Speciella klasser för `ggplot2`

*"In brief, the grammar tells us that a statistical graphic is a mapping from data to aesthetic attributes (colour, shape, size) of geometric objects (points, lines, bars). The plot may also contain statistical transformations of the data and is drawn on a specific coordinate system."*

*Från "ggplot2 book" av Hadley Wickham*

Kopplar ihop färg, form och utseende till data

aes	Beskrivning
x	x-axel
y	y-axel
size	storlek
color	färg
shape	form

Vilken geometrisk representation ska användas

geom	Beskrivning
geom_point	Scatterplot
geom_line	Line graph
geom_bar	Barplot
geom_boxplot	Boxplot
geom_histogram	Histogram

Finns även speciella aesthetics för vissa geoms

geom	aes
geom_points	point shape, point size
geom_line	line type, line size
geom_bar	y min, y max, fill color, outline color

## Exempel - I

```
ggplot(data = Nile) +  
  aes(x = years, y = level) +  
  geom_point()
```



F7\_johan\_files/figure-beamer/unnamed-chunk-2-1.pdf

## Exempel - II

```
ggplot(data = Nile) +  
  aes(x = years, y = level) +  
  geom_line()
```



F7\_johan\_files/figure-beamer/unnamed-chunk-3-1.pdf

```
ggplot(data = Nile) +  
  aes(x = years, y = level, color = period) +  
  geom_point(aes(shape = period))
```



F7\_johan\_files/figure-beamer/unnamed-chunk-4-1.pdf



```
ggplot(data = Nile) +  
  aes(x = years, y = level, color = period) +  
  geom_line() +  
  geom_point()
```



F7\_johan\_files/figure-beamer/unnamed-chunk-5-1.pdf

```
ggplot(data = Nile) +  
  aes(x = years, y = level) +  
  facet_grid(period ~ .) +  
  geom_line()
```



F7\_johan\_files/figure-beamer/unnamed-chunk-6-1.pdf

## Exempel - VI


```
p <- ggplot(data = Nile) +  
  aes(x = years, y = level) +  
  facet_grid(~ period) +  
  geom_line()  
print(p)
```



F7\_johan\_files/figure-beamer/unnamed-chunk-7-1.pdf

## Exempel - VII : Teman

```
p + theme_bw()
```



F7\_johan\_files/figure-beamer/unnamed-chunk-8-1.pdf

```
p + theme_calc()
```



F7\_johan\_files/figure-beamer/unnamed-chunk-9-1.pdf

```
p + theme_clean()
```



F7\_johan\_files/figure-beamer/unnamed-chunk-10-1.pdf

```
p + theme_minimal()
```



F7\_johan\_files/figure-beamer/unnamed-chunk-11-1.pdf

- `qplot()` liknar `plot()`
- Bra för snabba grafer
- För mer kontroll använd `ggplot()`



# Statistik

---

- Finns massor av olika statistiska tester
  - Väldigt många finns i R också
- För t-tester används `t.test()`
- För  $\chi^2$ -tester används
  - `chisq.test()`, `fisher.test()`
- Korrelation och kovarians kan beräknas och testas
  - `cor()` och `cov()`
  - `cor.test()`

## Exempel: t.test() - I

```
data("chickwts")  
horsebean <- chickwts$weight[chickwts$feed == "horsebean"]  
sunflower <- chickwts$weight[chickwts$feed == "sunflower"]
```

```
mean(horsebean)
```

```
## [1] 160.2
```

```
mean(sunflower)
```

```
## [1] 328.9167
```

## Exempel: t.test() - II

```
t.test(horsebean, alternative = "two.sided",  
       mu = 150, conf.level = 0.95)
```

```
##  
## One Sample t-test  
##  
## data: horsebean  
## t = 0.83507, df = 9, p-value = 0.4253  
## alternative hypothesis: true mean is not equal to 150  
## 95 percent confidence interval:  
## 132.5687 187.8313  
## sample estimates:  
## mean of x  
## 160.2
```

## Exempel: t.test() - III

```
t.test(horsebean, sunflower,  
       alternative = "two.sided",  
       mu = 0, conf.level = 0.95)  
  
##  
## Welch Two Sample t-test  
##  
## data: horsebean and sunflower  
## t = -9.0449, df = 19.964, p-value = 1.69e-08  
## alternative hypothesis: true difference in means is not  
## 95 percent confidence interval:  
## -207.6313 -129.8021  
## sample estimates:  
## mean of x mean of y  
## 160.2000 328.9167
```

# Linjär regression

---

- I R finns formelobjektet som beskriver relationer mellan variabler
  - Formel skapas med `~`
  - Exempel: `y ~ x1 + x2`
- Att arbeta med modeller i R kan delas in i fyra steg:
  1. Anpassa (träna) en modell
  2. Analysera/studera resultatet
  3. Diagnostisera
  4. Använda modellen och resultaten
- Linjär regression handlar om att hitta en linjär modell

# Linjär regression - Anpassa en modell

- Behöver en formel och data
- Data behöver samma variabler som formeln

```
library(MASS)
library(car)
data(Prestige)
```

```
mod1 <- lm(prestige ~ income + women + education, data=Pres
```

```
mod2 <- lm(prestige ~ income + women + education - 1, data=
```

```
mod3 <- lm(prestige ~ income:women + education, data=Prestr
```



- Använd följande funktioner för att studera resultatet
  - `summary()`
  - `anova()`

Exempel:

```
summary(mod1)
anova(mod1)
anova(mod1, mod2, test = "Chisq")
```

- Finns ett antal olika metoder, ex:

```
plot(mod1)
durbinWatsonTest(mod1)
qqplot(mod1)
```

- När vi har en modell kan vi göra olika saker:
  - Publicera modellen
  - Studera residualer
  - Prediktion
- Vi kan spara vår modell och använda
  - `resid()`
  - `predict()`