R-programmering VT26

Föreläsning 7

Johan Alenlöv

Linköpings Universitet

Föreläsning 7

Innehåll föreläsning 7

- Grafik med `ggplot2`
- Grundläggande statistik
- Linjär regression

ggplot2

ggplot2

- Skapat av Hadley Wickham för över 10 år sedan
- Baseras på "Grammar of Graphics" av Leland Wilkinson
- Alternativ till basgrafiken
- Grunden är alltid en `data.frame`

Grammar of Graphics

- Abstraktion av grafiska idéer
  - Tänk språk med ordklasser/satsdeelar
- Ger ett teoretiskt ramverk för att bygga grafik.
- Bygga upp grafik lager för lager

ggplot2

- Bygger upp en graf av flera delar:
  - `data`: en `data.frame` med **all** data
  - `aes`: asethetic mappings
  - `geom`: geometriska objekt
  - `facets`: subplottar
  - `scales`: skalor
  - `coordinate system`: koordinatsystem

ggplot2

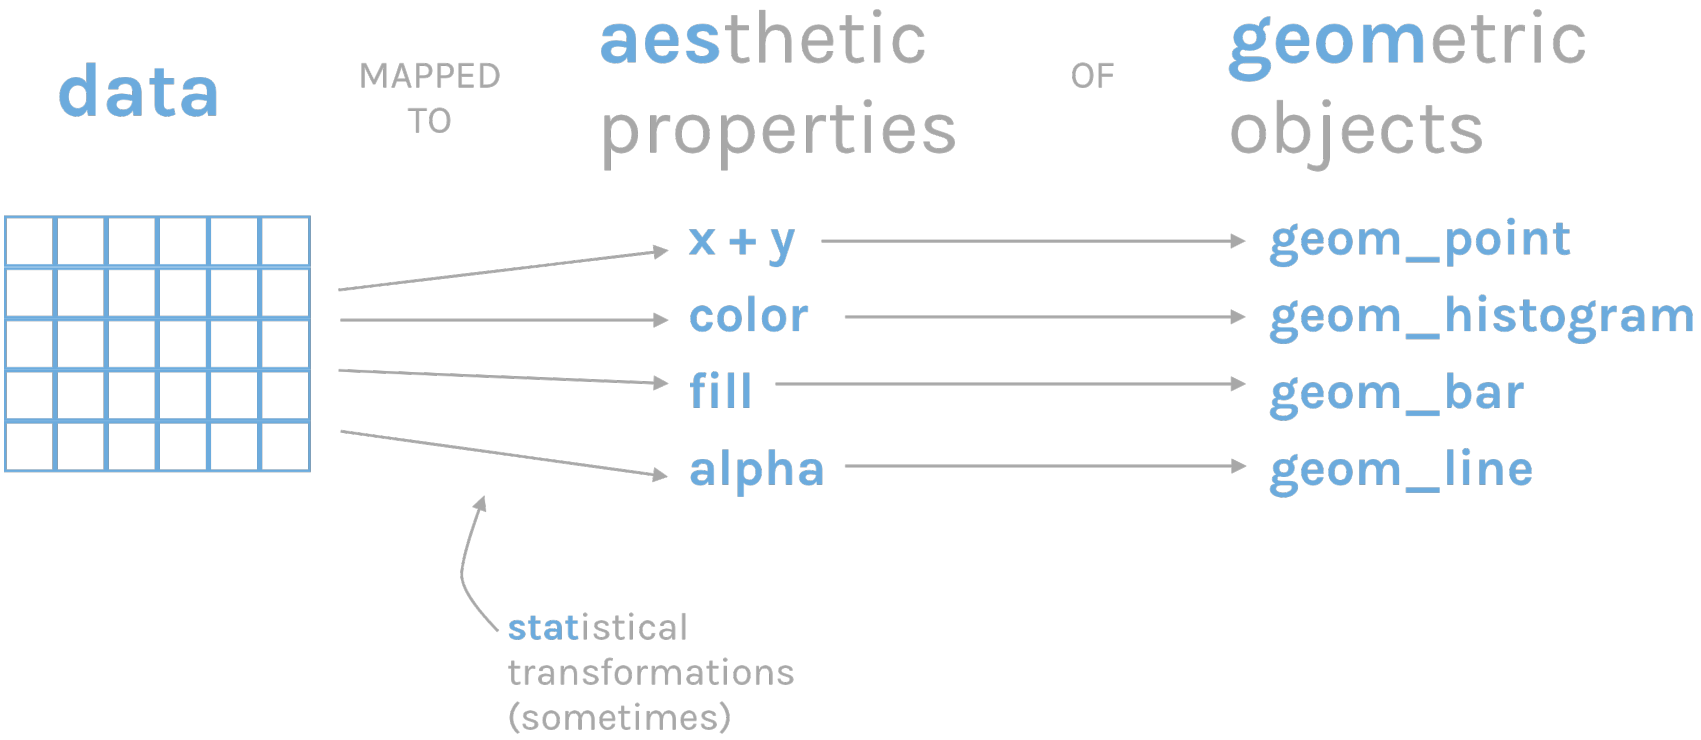

Bild från “R for the rest of us”

ggplot2

- `ggplot2` bygger upp en plot med olika lager
  - När plotten är klar så visas den
  - Kan också visa med `print()`
- Utgår från `ggplot()`
  - Returnerar ett objekt
- Adderar lager med +
  - t.ex. `+ geom_point()`
- Speciella klasser för `ggplot2`

Grammar of Graphics

"In brief, the grammar tells us that a statistical graphic is a mapping from data to aesthetic attributes (colour, shape, size) of geometric objects (points, lines, bars). The plot may also contain statistical transformations of the data and is drawn on a specific coordinate system."

Från "ggplot2 book" av Hadley Wickham

aesthetic (aes)

Kopplar ihop färg, form och utseende till data

aes	Beskrivning
`x`	x-axel
`y`	y-axel
`size`	storlek
`color`	färg
`shape`	form

geometric (geom)

Vilken geometrisk representation ska användas

geom	Beskrivning
`geom_point`	Scatterplot
`geom_line`	Line graph
`geom_bar`	Barplot
`geom_boxplot`	Boxplot
`geom_histogram`	Histogram

aes och geom

Finns även speciella aesthetics för vissa geoms

geom	aes
`geom_points`	point shape, point size
`geom_line`	line type, line size
`geom_bar`	y min, y max, fill color, outline color

Exempel - I

```
ggplot(data = Nile) +
  aes(x = years, y = level) +
  geom_point()
```

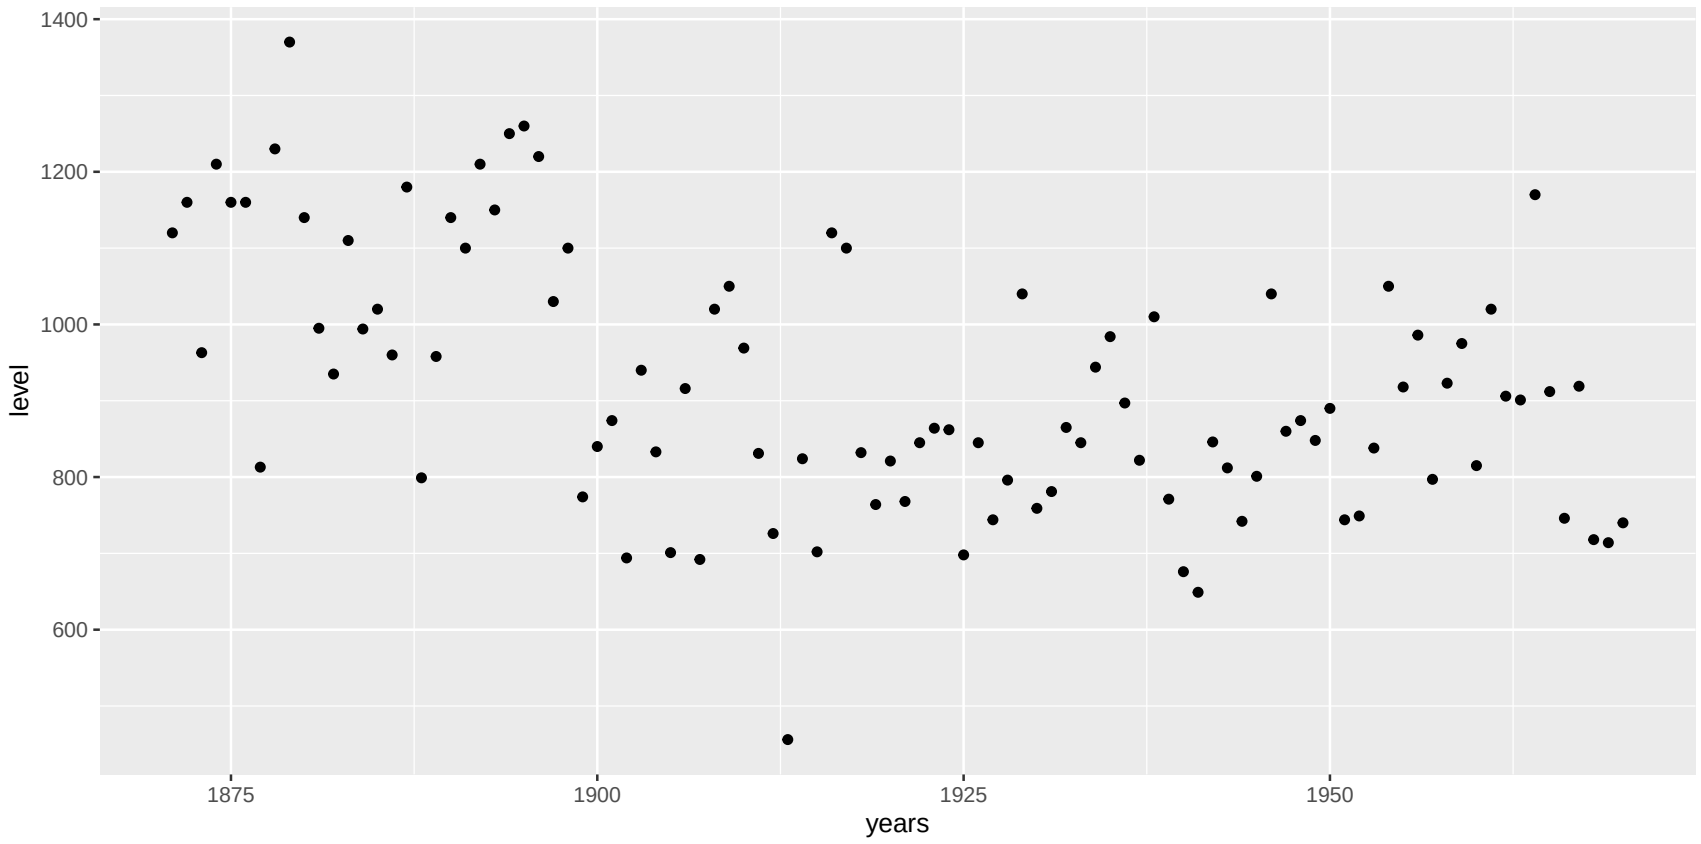

Exempel - II

```r
ggplot(data = Nile) +
  aes(x = years, y = level) +
  geom_line()
```

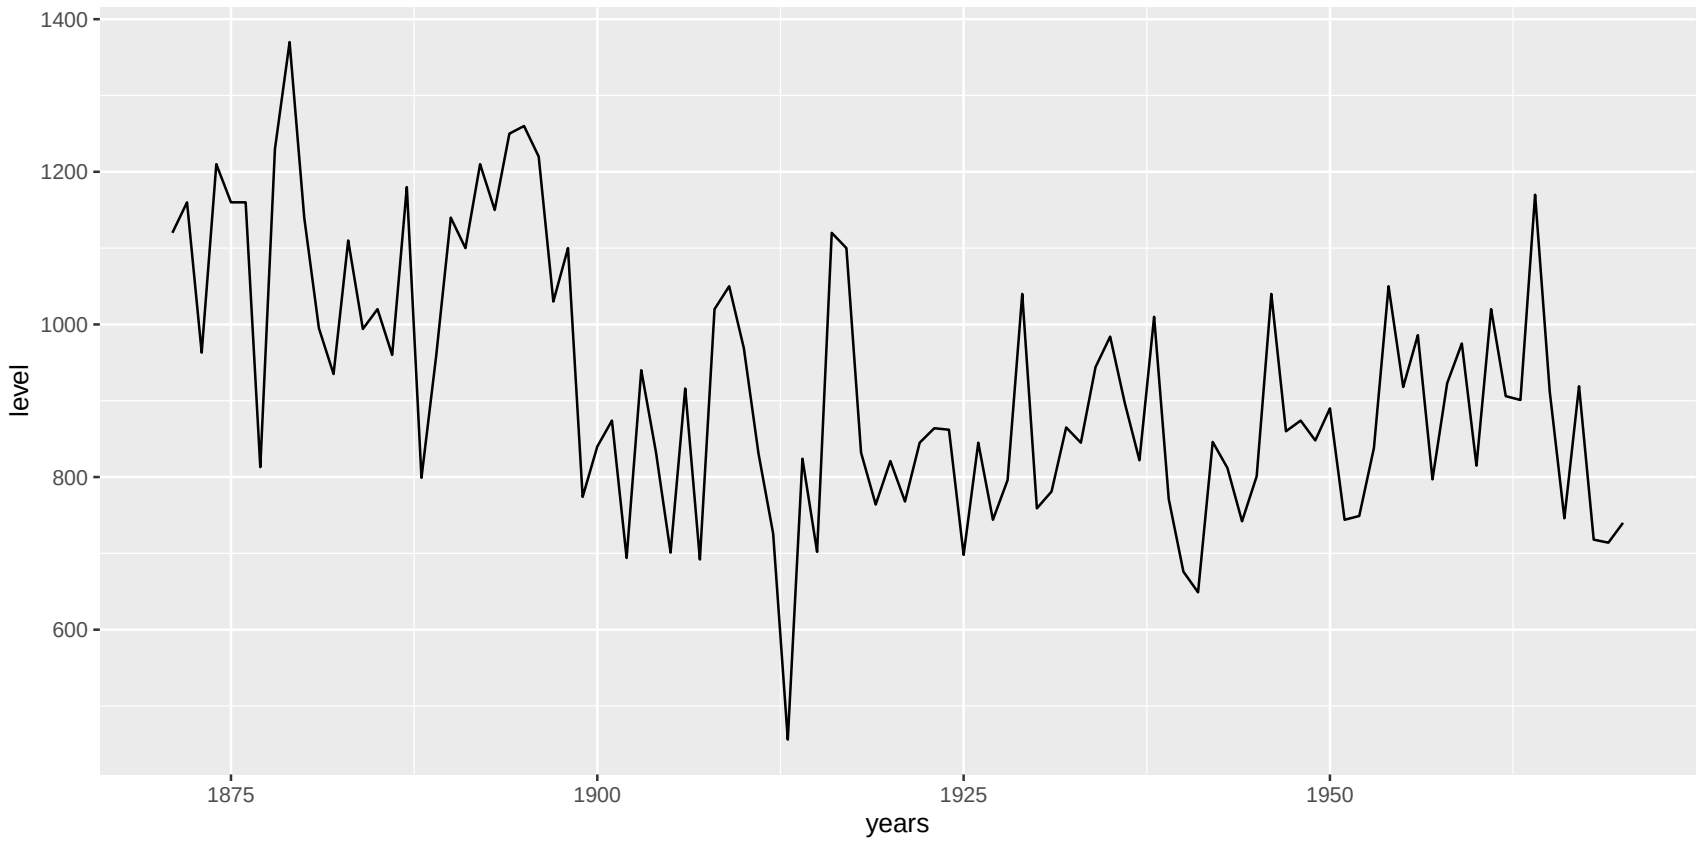

Exempel - III

```
ggplot(data = Nile) +
  aes(x = years, y = level, color = period) +
  geom_point(aes(shape = period))
```

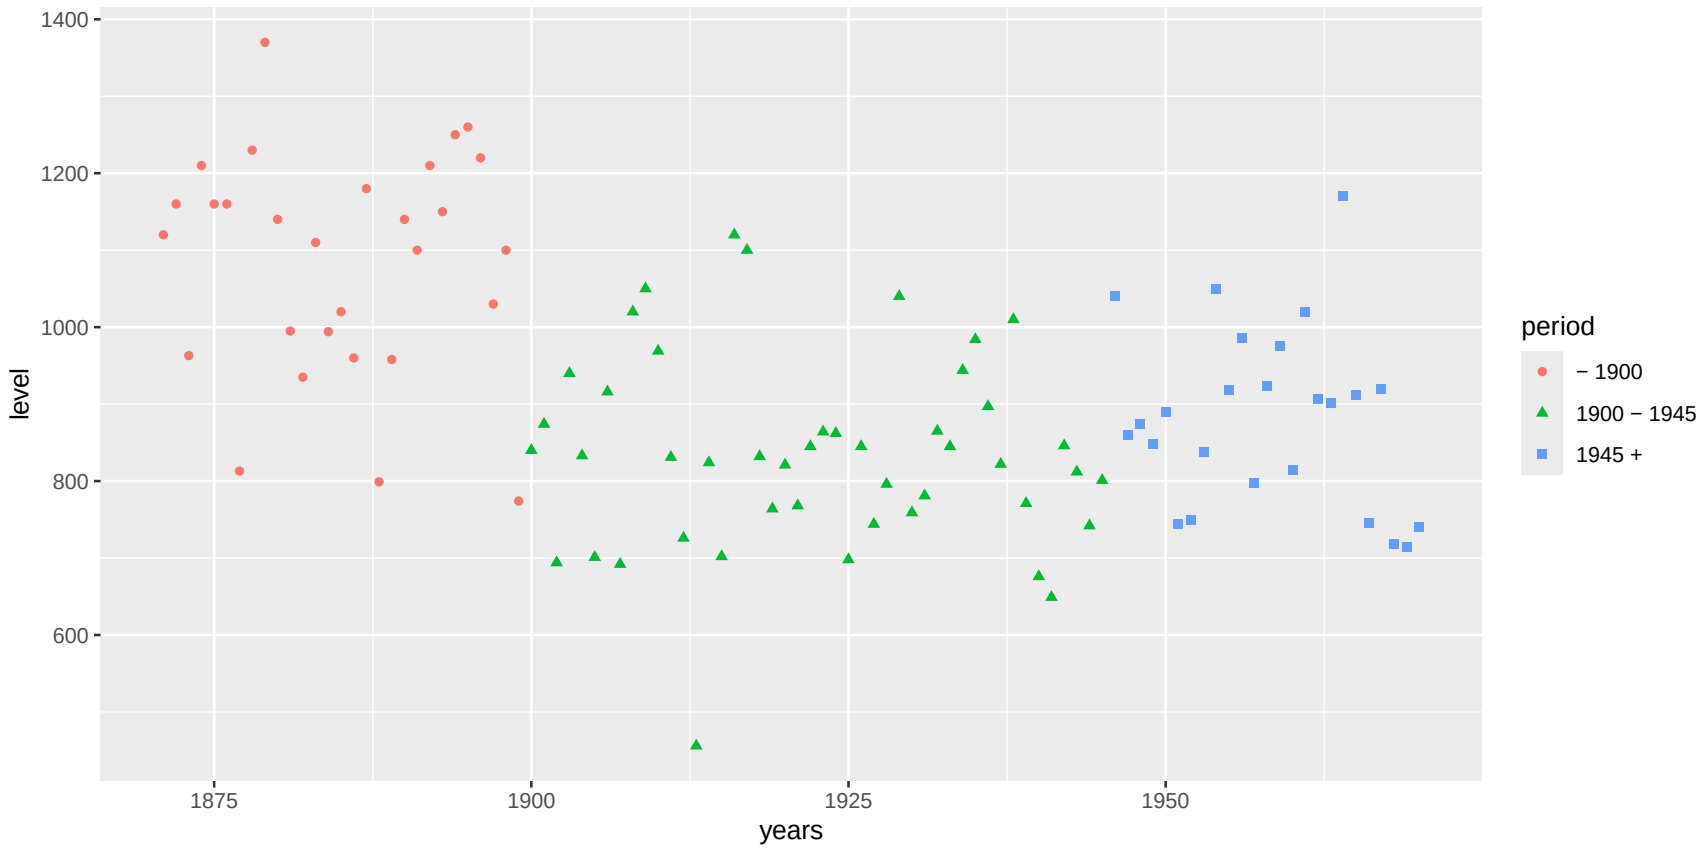

Exempel - IV

```
ggplot(data = Nile) +
  aes(x = years, y = level, color = period) +
  geom_line() +
  geom_point()
```

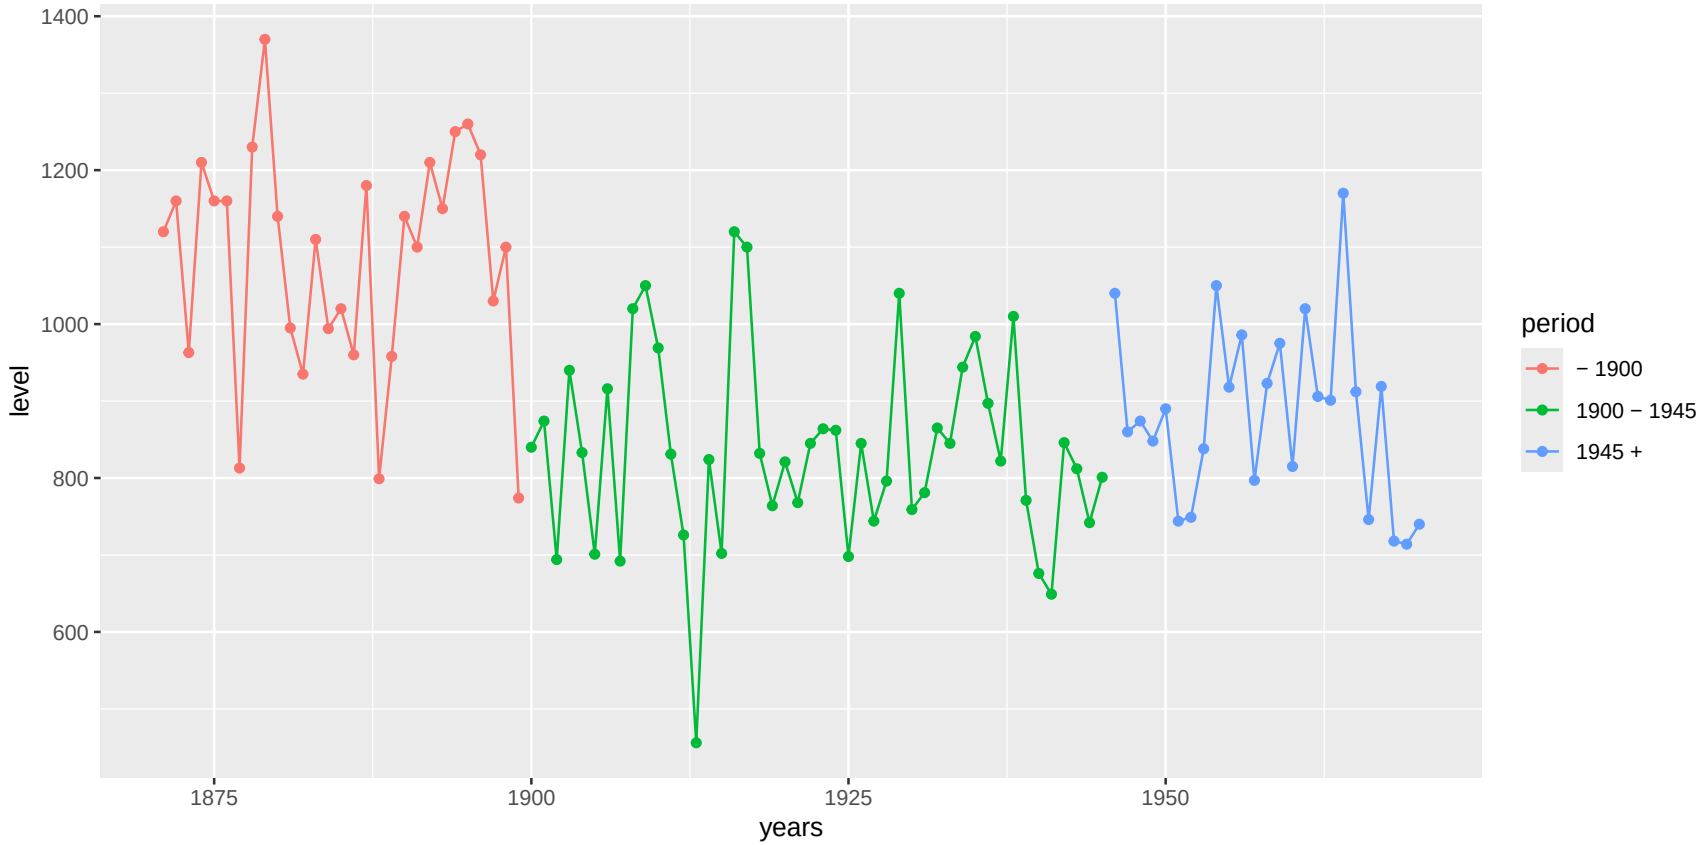

Exempel - V

```
ggplot(data = Nile) +
  aes(x = years, y = level) +
  facet_grid(period ~ .) +
  geom_line()
```

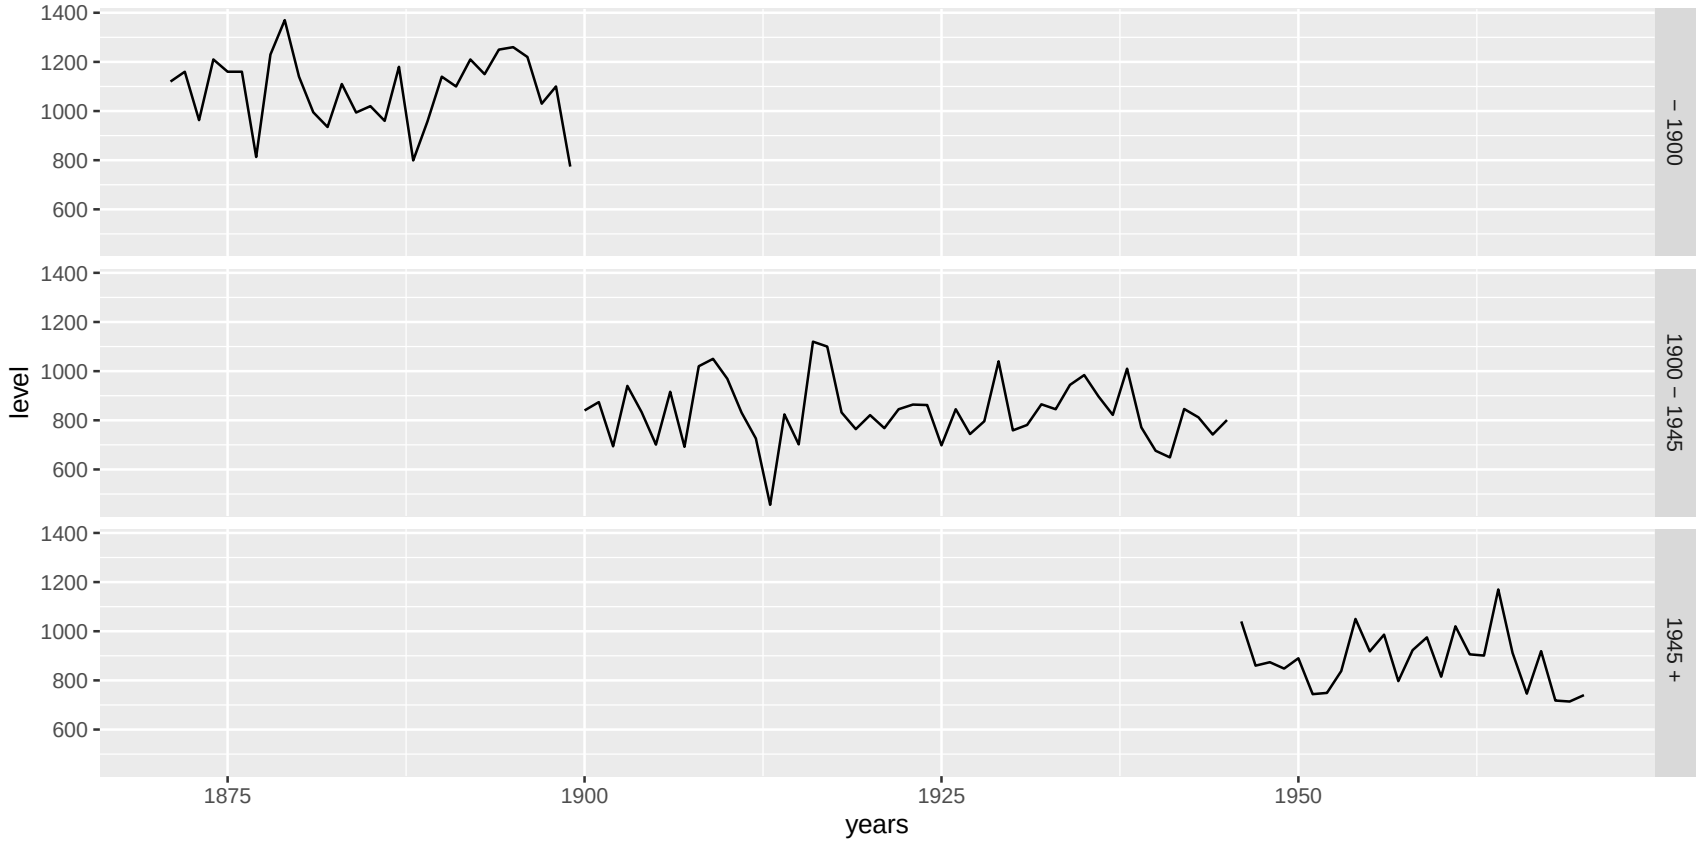

Exempel - VI

```r
p <- ggplot(data = Nile) +
  aes(x = years, y = level) +
  facet_grid(~ period) +
  geom_line()
print(p)
```

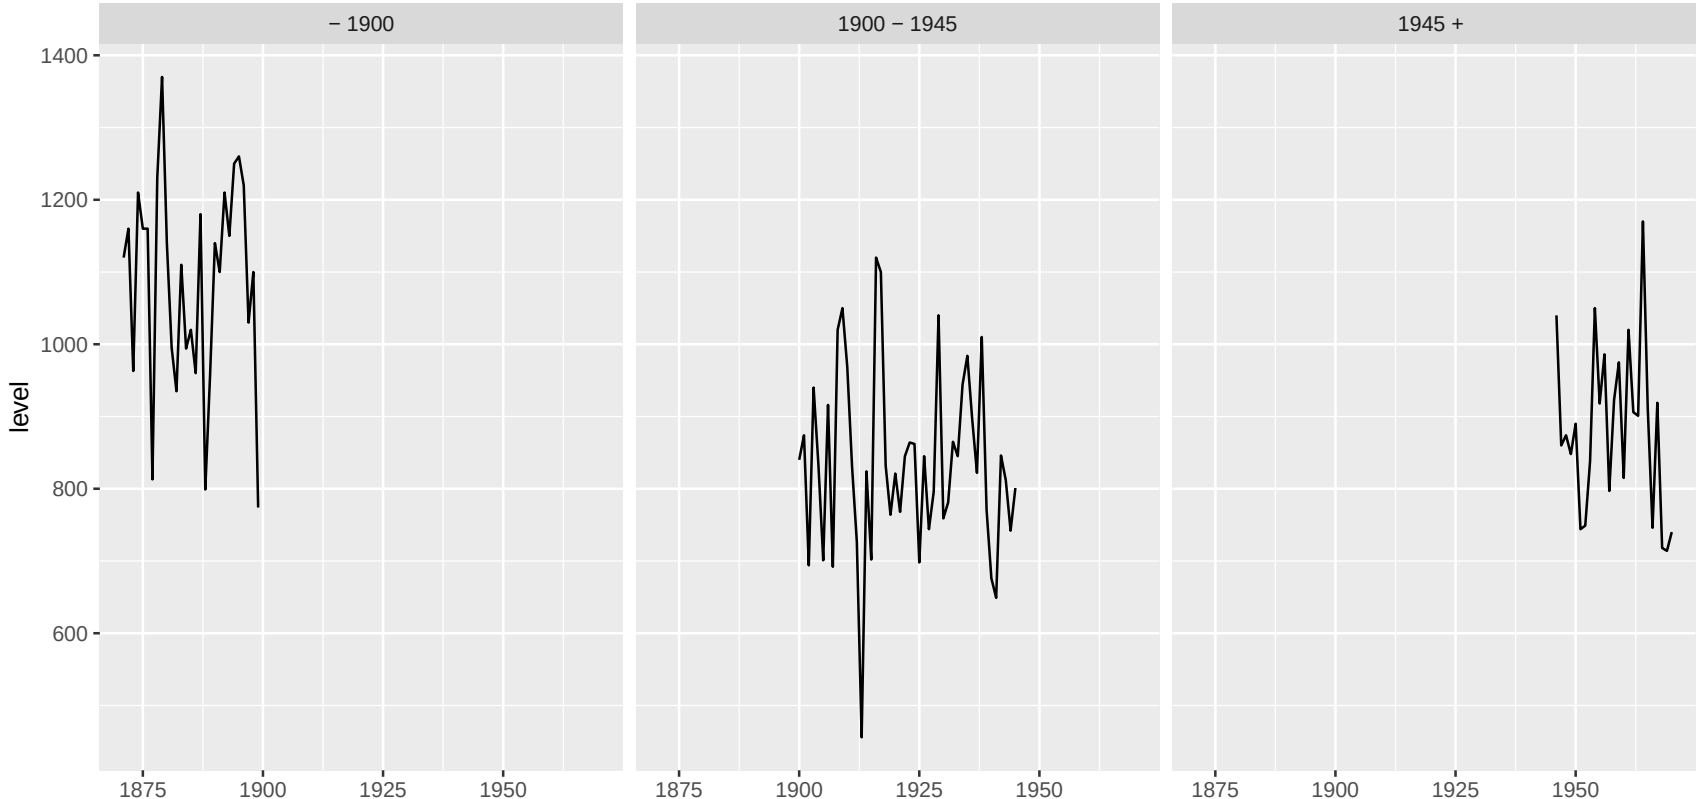

Exempel - VII : Teman

```
p + theme_bw()
```

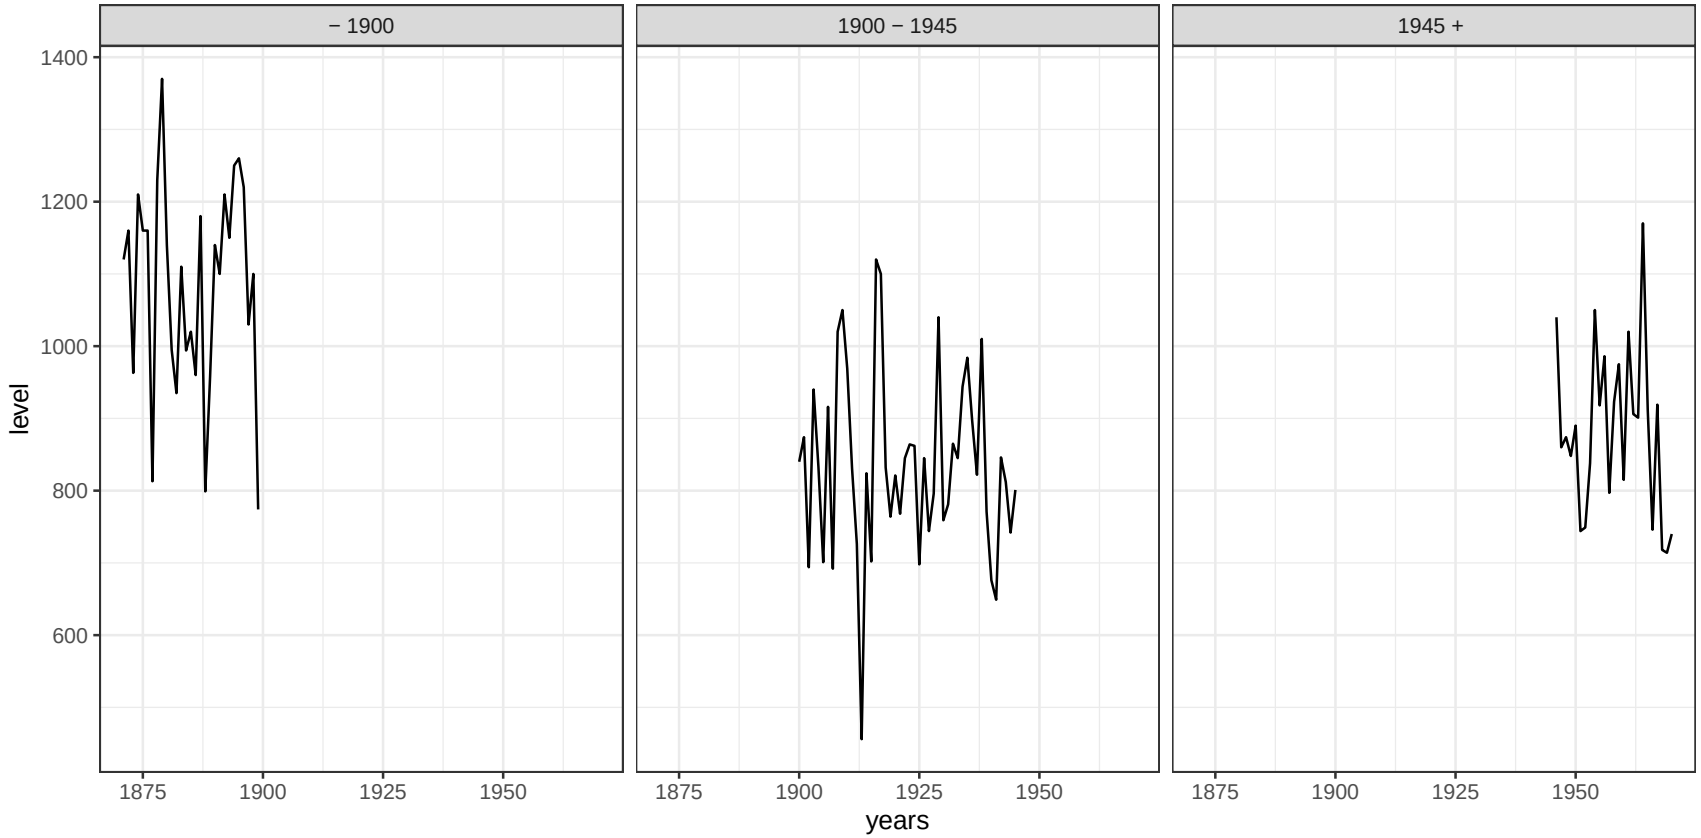

Exempel - VIII : Teman

```
p + theme_calc()
```

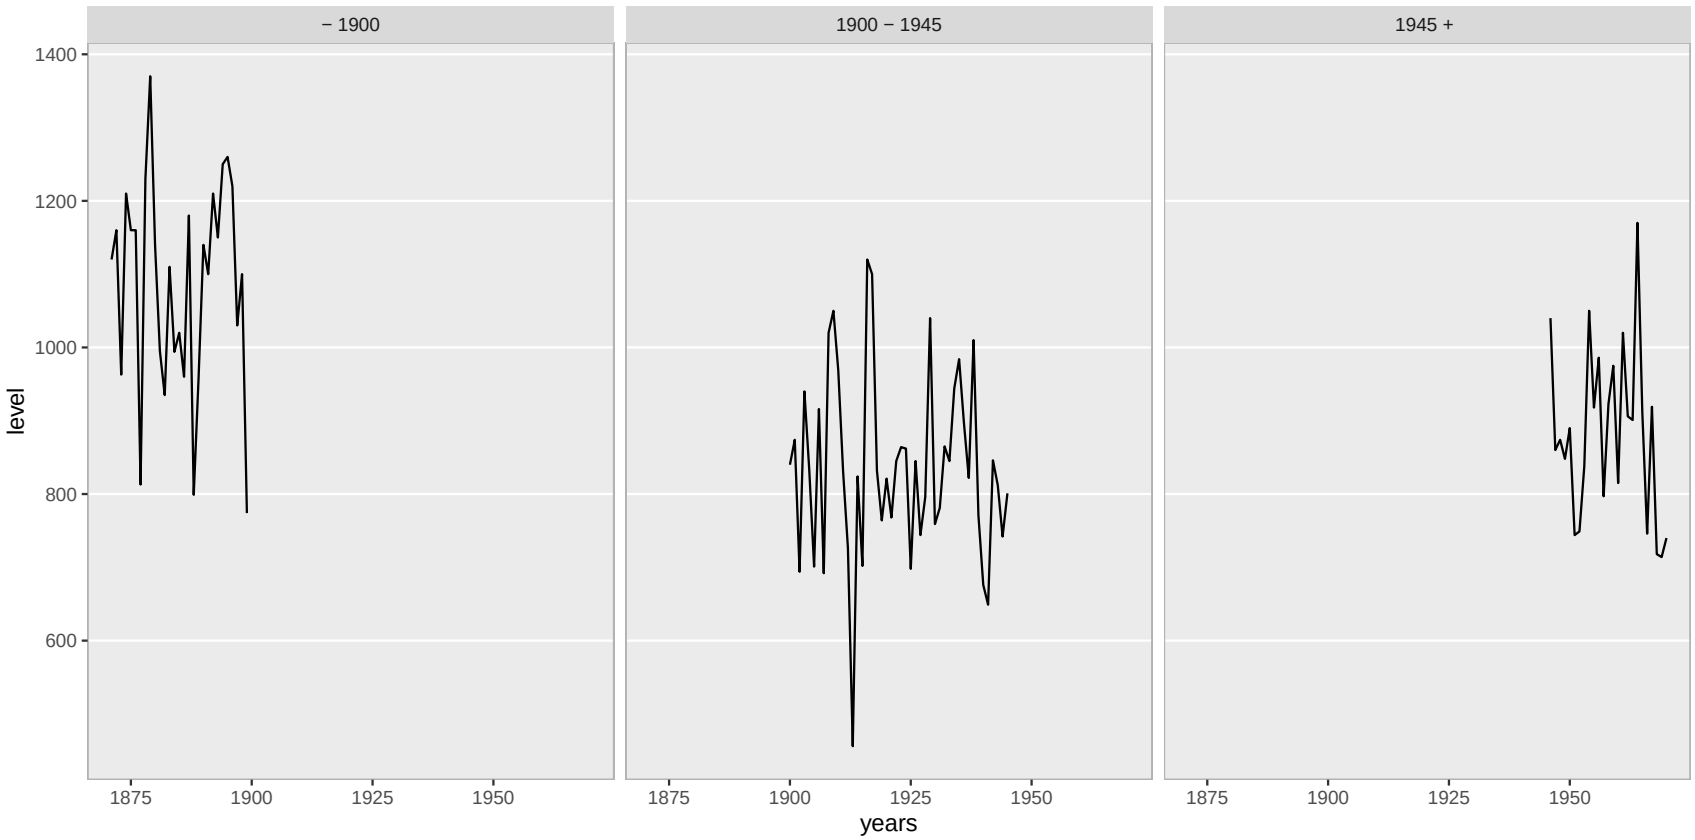

Exempel - IX : Teman

```
p + theme_clean()
```

```
## Warning: The `size` argument of `element_line()` is depr
## i Please use the `linewidth` argument instead.
## i The deprecated feature was likely used in the ggthemes
##   Please report the issue at <https://github.com/jrnold/
## This warning is displayed once per session.
## Call `lifecycle::last_lifecycle_warnings()` to see where
## generated.
```

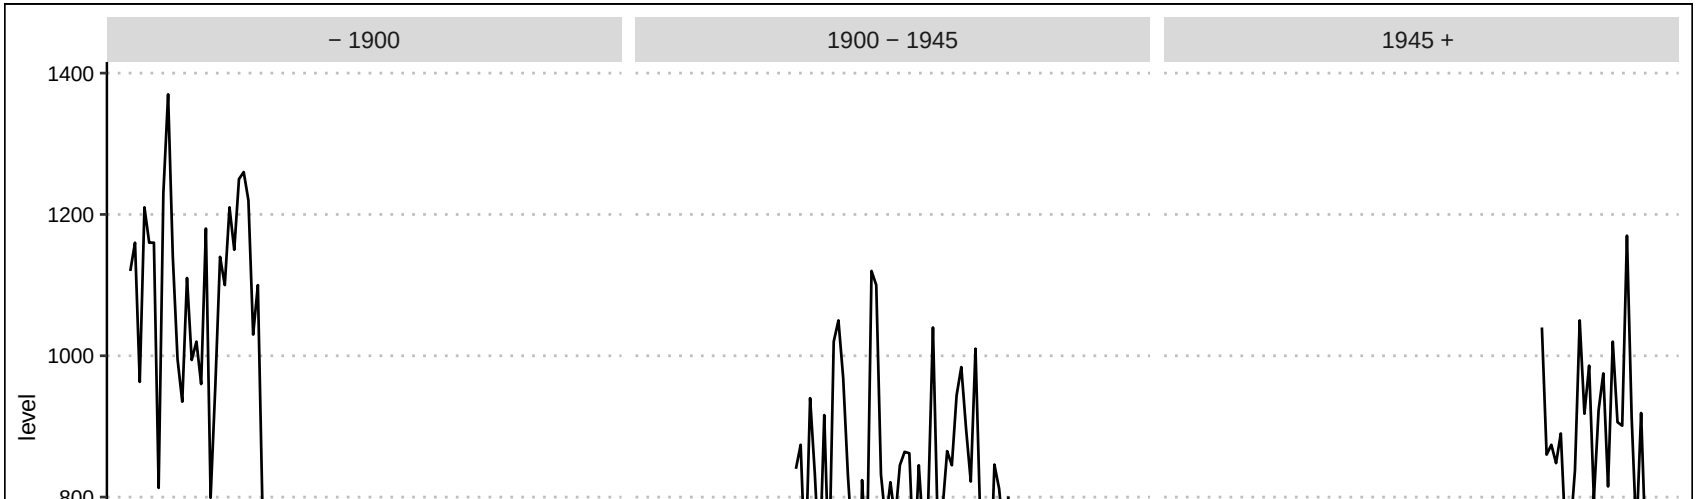

Exempel - X : Teman

```
p + theme_minimal()
```

`qplot`

- `qplot()` liknar `plot()`
- Bra för snabba grafer
- För mer kontroll använd `ggplot()`

Demo

Demo: ggplot

Statistik

Enklare statistika tester

- Finns massor av olika statistiska tester
  - Väldigt många finns i R också
- För t-tester används `t.test()`
- För χ^2-tester används
  - `chisq.test()`, `fisher.test()`
- Korrelation och kovarians kan beräknas och testas
  - `cor()` och `cov()`
  - `cor.test()`

Exempel: t.test() - I

```r
data("chickwts")
horsebean <- chickwts$weight[chickwts$feed == "horsebean"]
sunflower <- chickwts$weight[chickwts$feed == "sunflower"]

mean(horsebean)
```

```
## [1] 160.2
```

```r
mean(sunflower)
```

```
## [1] 328.9167
```

Exempel: t.test() - II

```r
t.test(horsebean, alternative = "two.sided",
       mu = 150, conf.level = 0.95)
```

```
##
##  One Sample t-test
##
## data:  horsebean
## t = 0.83507, df = 9, p-value = 0.4253
## alternative hypothesis: true mean is not equal to 150
## 95 percent confidence interval:
##  132.5687 187.8313
## sample estimates:
## mean of x
##     160.2
```

Exempel: t.test() - III

```r
t.test(horsebean, sunflower,
       alternative = "two.sided",
       mu = 0, conf.level = 0.95)
```

```
##
##  Welch Two Sample t-test
##
## data:  horsebean and sunflower
## t = -9.0449, df = 19.964, p-value = 1.69e-08
## alternative hypothesis: true difference in means is not
## 95 percent confidence interval:
##  -207.6313 -129.8021
## sample estimates:
## mean of x mean of y
##  160.2000  328.9167
```

Demo

Demo: Statistik

Linjär regression

Linjär regression

- I R finns formelobjektet som beskriver relationer mellan variabler
  - Formel skapas med ~
  - Exempel: `y ~ x1 + x2`
- Att arbeta med modeller i R kan delas in i fyra steg:
  1. Anpassa (träna) en modell
  2. Analysera/studera resultatet
  3. Diagnostisera
  4. Använda modellen och resultaten
- Linjär regression handlar om att hitta en linjär modell

Linjär regression - Anpassa en modell

- Behöver en formel och data
- Data behöver samma variabler som formeln

```
library(MASS)
library(car)
data(Prestige)
```

```
mod1 <- lm(prestige ~ income + women + education, data=Pres
```

```
mod2 <- lm(prestige ~ income + women + education - 1, data=
```

```
mod3 <- lm(prestige ~ income:women + education, data=Presti
```

Linjär regression - Analysera modellen

- Använd följande funktioner för att studera resultatet
  - `summary()`
  - `anova()`

Exempel:

```
summary(mod1)
anova(mod1)
anova(mod1, mod2, test = "Chisq")
```

Linjär regression - Diagnostisera

- Finns ett antal olika metoder, ex:

```
plot(mod1)
durbinWatsonTest(mod1)
qqplot(mod1)
```

Linjär regression - Använda modellen

- När vi har en modell kan vi göra olika saker:
  - Publicera modellen
  - Studera residualer
  - Prediktion
- Vi kan spara vår modell och använda
  - `resid()`
  - `predict()`

Demo

Demo: Linjär regression